

Sistema de Recuperación Aumentada de Información para la resolución de Anomalías en Líneas de Producción

Christian Adriel Rodriguez Narvaez

Universidad Autónoma de Yucatán / Uchiyama Manufacturing de Yucatán

adrielchris7.com

5 de octubre de 2026

Resumen

Uno de los principales problemas en la industria de la manufactura es la variedad de fallas y anomalías que se pueden presentar a lo largo del día y en los diferentes turnos. La resolución rápida de estos inconvenientes suele depender del conocimiento del personal operativo en turno, de los ingenieros a cargo y, en ocasiones, de si el gerente se encuentra presente en la planta.

En muchas ocasiones, la cantidad de información que se maneja es masiva, lo que dificulta encontrar soluciones en un tiempo óptimo sin detener la producción.

Este artículo presenta un sistema basado en Generación Aumentada por Recuperación (RAG, por sus siglas en inglés), diseñado para asistir a los operadores e ingenieros de planta en la toma de decisiones.

La solución propuesta utiliza los registros de producción estructurados bajo el enfoque de las 4M, lo que permite consultar recomendaciones en tiempo real.

Los resultados demuestran que la aplicación de este sistema inteligente reduce la dependencia de la presencia de personal de supervisión o gerencial en turno para la resolución de problemas.

Palabras clave— Sistema de Recuperación Aumentada de Información (RAG), Metodología 4M'S, Diagnostico de fallas, Inteligencia Artificial en la Industria de Manufactura.

1. Introducción

En la industria manufacturera por inyección de caucho, la continuidad operacional y la minimización de los tiempos de paro en las líneas de producción son factores críticos para mantener la calidad del producto, cumplir con la demanda actual y conservar la competitividad. Durante los turnos de trabajo a menudo es habitual que surjan anomalías de calidad, fallas mecánicas u otro tipo de imprevistos que requieren intervenciones inmediatas. La resolución de estos incidentes ha dependido históricamente de la experiencia y disponibilidad de los supervisores o gerentes del área de producción.

En esquemas de producción continua donde la presencia de personal de supervisión o gerencial es limitada, los operadores e ingenieros enfrentan el reto de diagnosticar y corregir problemas de manera autónoma. El acceso a la información técnica suele ser lento e ineficiente, ya que la consulta manual de bitácoras, instructivos de trabajo o registros históricos durante una situación anómala no resulta práctica en el piso de producción.

La llegada de los modelos LLM (Large Language Models, por sus siglas en inglés) ha transformado la interacción mediante lenguaje natural, pero su aplicación directa presenta limitaciones, como el desconocimiento de procedimientos internos y el riesgo de generar respuestas imprecisas o alucinadas. Para superar esta barrera, la arquitectura de Generación Aumentada por Recuperación (RAG) surge como una solución efectiva que combina la capacidad conversacional de

los LLM con la precisión de bases de conocimiento privadas.

En este trabajo se presenta el diseño e implementación de un sistema RAG especializado en la ingesta y consulta de documentación operacional del registro de las 4M (Mano de Obra, Maquinaria, Materiales y Métodos). La herramienta permite a los operadores e ingenieros en turno formular dudas operativas en lenguaje natural y recibir recomendaciones contextualizadas y respaldadas por registros históricos de la producción, reduciendo la brecha generada por la ausencia de supervisores o personal gerencial.

2. Metodología

2.1. Descripción general del sistema

El sistema implementa el flujo estándar de un pipeline RAG, dividido en dos fases (Figura 1):

- **Indexación:** Fase *offline* al cargar los documentos.
- **Consulta:** Fase *online* para procesar la pregunta del usuario.

Ambas fases comparten el mismo modelo de embedding para mantener la comparabilidad vectorial.

2.2. Componentes del código

El sistema se organiza en módulos con una responsabilidad única, lo que permite reemplazar cualquier pieza sin alterar el resto del pipeline.

- **chunk.py:** Extrae el texto plano del documento cargado y lo fragmenta por número de palabras, generando una lista de *chunks* con metadatos (*source*, *page*).
- **embed.py:** Encapsula la comunicación con la API de embeddings de Google AI. Expone dos métodos diferenciados mediante **task_type** (**RETRIEVAL_DOCUMENT** y **RETRIEVAL_QUERY**), y agrupa los *chunks* en lotes (*batching*) para reducir el número de llamadas a la API.




Figura 1: Flujo general del sistema RAG: fase de indexación (izquierda) y fase de consulta (derecha).

- **store.py:** Envuelve a **ChromaDB**. Administra la persistencia en disco, la inserción de vectores y la búsqueda por similitud coseno (*search*).
- **generate.py:** Construye el prompt de generación (contexto numerado más la instrucción explícita de abstención).
- **main.py:** Expone la lógica anterior como una API REST mediante **FastAPI**. Recibe la solicitud, coordina los módulos anteriores y aplica el umbral de abstención antes de invocar al modelo generador.
- **streamlit_app.py:** Interfaz de usuario que consume la API vía HTTP.

2.3. Dominio y composición del corpus

El sistema no impone restricciones de dominio; el alcance está determinado exclusivamente por el conjunto de documentos que se introduzcan, admitiendo formatos PDF, TXT y MD.

Para la generación de embeddings se emplea **gemini-embedding-001** (3072 dimensiones). Un único modelo representa tanto los documentos del corpus como las consultas del usuario, diferenciándolos únicamente por el parámetro **task_type** (**RETRIEVAL_DOCUMENT** o **RETRIEVAL_QUERY**). Esto es necesario porque la búsqueda k-NN presupone que los vectores comparados habitan en el mismo espacio semántico; usar modelos distintos para documentos y consultas invalidaría la comparación.

El tamaño exacto del corpus (número de documentos y *chunks*) depende del conjunto cargado en cada instancia y se reporta con los valores reales obtenidos de los endpoints `/health` y `/documents` al momento de la evaluación.

2.4. Estrategia de fragmentación

La fragmentación se realizó por palabras: cada *chunk* consta de 300 palabras con un traslape de 50 palabras entre cada fragmento consecutivo.

Se definieron 300 palabras como un punto medio ideal. Si los *chunks* son muy pequeños, una misma idea termina dividida en varios pedazos y se pierde precisión al buscar. Si son muy grandes, el embedding termina representando varios temas distintos mezclados en un solo vector. 300 palabras son suficientes para poder cubrir una idea completa sin meter temas de más.

Si no hay un **traslape**, una idea se puede quedar justo en el límite entre dos *chunks*, cortándose a la mitad sin que ningún fragmento la contenga completa. El traslape sirve de colchón para evitar que eso pase. El costo es que se generan un poco más de *chunks* de los que harían falta sin traslape, pero vale la pena porque mejora significativamente la cobertura de la información recuperada.

2.5. Mecanismo de abstención

El sistema usa dos capas de abstención para minimizar alucinaciones:

- **Capa 1. Umbral de distancia:** La colección de ChromaDB se configura con métrica coseno (`hnsw:space=cosine`), la cual ofrece

un rango interpretable de 0 (idéntico) a 2 (opuesto). Si no se recupera ningún *chunk*, o si el más cercano supera el valor de **ABSTENTION_DISTANCE_THRESHOLD** (0.8 por defecto), el sistema se abstiene sin invocar al modelo generador, ahorrando cuota y evitando enviar contexto irrelevante.

- **Capa 2. Restricción instruccional:** Un umbral numérico no detecta cuando el contexto es temáticamente cercano pero insuficiente para responder una pregunta puntual. Por ello, el prompt instruye al modelo a responder únicamente con la evidencia dada y a emitir un mensaje de abstención fijo cuando el contexto no alcance; la respuesta generada se coteja contra ese mensaje para derivar el indicador **abstained**.

2.6. División de Responsabilidades

Cuadro 1: División de responsabilidades: Google AI y ChromaDB

Función	Responsable
Embeddings de documentos y consultas	Google AI (gemini-embedding-001)
Generación de la respuesta en lenguaje natural	Google AI (gemini-3.6-flash)
Persistencia de vectores, texto y metadatos	ChromaDB
Indexación y búsqueda k-NN	ChromaDB

ChromaDB no ejerce ninguna función de comprensión del contenido: su operación se limita a comparar vectores generados previamente por el modelo de embedding.

Toda capacidad de procesamiento semántico —entender la consulta, extraer significado del corpus, redactar la respuesta— reside exclusivamente en los modelos de Google AI; ChromaDB es la capa de infraestructura de recuperación, no de razonamiento.

3. Experimentos y Resultados

3.1. StreamLit

En la siguiente imagen podemos encontrar los resultados aplicados a un entorno donde un operador de producción o un ingeniero ingresa una pregunta sobre un problema de piezas vulcanizadas en una máquina en específico, en este caso hace referencia a la máquina número 21.



Figura 2: Imagen de un prompt y su respuesta

3.2. Pregunta fuera de dominio

Ahora, en la siguiente imagen podemos observar cómo el sistema reacciona cuando el usuario introduce una pregunta fuera de dominio. El sistema evitará hacer respuestas inventadas, lo que ayudará a evitar información errónea a los operadores/ingenieros al momento de buscar una solución, lo que previene acciones que impacten de manera negativa al producto y no se detenga la producción.




Figura 4: Respuesta fuera de dominio y muestra de la abstención




Figura 3: Las referencias usadas para generar la respuesta

3.3. Misma pregunta en /docs




Figura 5: Consulta y respuesta desde la interfaz /docs



Figura 6: Detalle del arreglo de citas y distancias en /docs

Como podemos observar la respuesta fue positiva, ya que la información proporcionada en los documentos de 4M'S previamente cargados tienen registro de un problema similar y con la solución adecuada. De igual forma la respuesta incluye la fecha en la que sucedió ese problema, lo que facilitaría la investigación en caso de alguna queja de cliente; el acceso a la información será más rápido y eficiente.

4. Conclusiones y Trabajo Futuro

Los resultados obtenidos reafirman la eficiencia de los sistemas RAG al momento de la recuperación de información. Como pudimos ver en la sección anterior, el sistema evita inventar o dar respuestas sin una referencia previamente cargada, lo que resulta positivo si hablamos de implementar un sistema RAG en un proceso de manufactura.

Al ser procesos muy complicados y que tienen un impacto significativo en la calidad del producto y en la producción, necesitamos que las respuestas sean lo más asertivas posibles, lo cual el sistema actual cumple con las necesidades de la producción.

De igual forma, es un sistema amigable al funcionar con lenguaje natural, lo que facilita su uso para cualquier operador o ingeniero en turno donde no se cuenta con personal gerencial.

Esta tecnología es muy útil para la industria de la manufactura. En el futuro sería ideal que se pueda aplicar a todos los procesos dentro de la planta; ya sean procesos de calidad para poder tener a la mano cualquier requerimiento del cliente sin la necesidad de buscar un manual o un documento con muchas hojas, o también en procesos administrativos, como poder consultar información de algún colaborador con solo realizar una pregunta y no tener que entrar a los expedientes y buscar dentro de mucha información.

Los planes a futuro, al menos dentro del área de producción, son seguir alimentando la base con información del proceso y asegurarnos de que sea lo más confiable, por lo que se necesitará la aprobación del gerente de área; entre más información tenga, de mayor utilidad será para el personal.

información para aplicar estos conocimientos en un entorno de producción real, haciendo posible la validación práctica de este proyecto.

Agradecimientos

Expreso mi sincero agradecimiento a la **Universidad Autónoma de Yucatán (UADY)** por brindar el espacio académico, las herramientas y la formación necesarias para el desarrollo de este trabajo.

Asimismo, agradezco a **Uchiyama Manufacturing de Yucatán** por la apertura, el apoyo con la